ENGINEERING EVALUATION / 2026.11.03

力学工程自主决策 Agent Benchmark

八道任务设计、受控工具执行与第一轮真实试跑

AlexanderChan

开发版范围. 已定义 8 道任务，当前 2 道一维力学算例可执行。4 次有效试跑中 3 次通过，1 次输出预算耗尽；另保留 2 次环境或适配器无效探测。尚未完成三维工业算例、商业求解器任务评测或模型排行榜。

1 为什么评测力学决策

评测关注模型能否从物理要求出发，选择区域、载荷、离散精度和验证方法，并交付可检查的工程结果。完成消息不是求解证据，工具调用格式正确也不是力学正确。CORE 表示保留细节的核心区，SUB 表示凝聚后的子结构区；两者应由响应与适用条件决定，而不是预先赋予重要性标签。

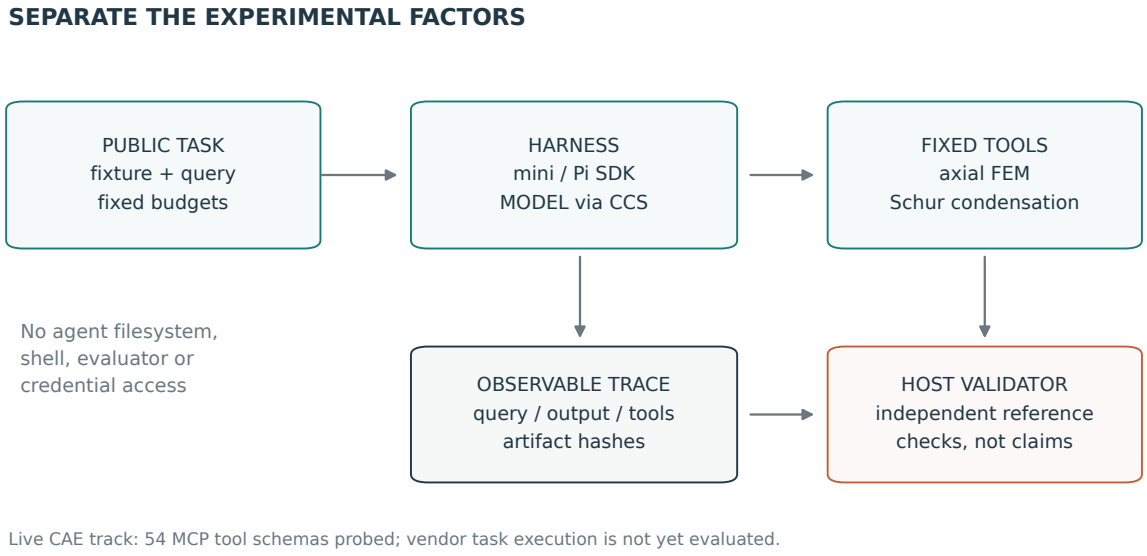


图 1: 模型、执行框架、受控工具与独立评分分层。图中实线表示当前试跑路径；54 个商业 CAE MCP 工具仅完成连接与 schema 预检，尚未作为参评任务调用。

2 八道任务与执行状态

ID	任务	状态
M01	载荷、单位与平衡	力学算例可执行
M02	力学驱动网格分配	规范已定义
M03	非线性预压与接触	规范已定义
M04	自主子结构区域决策	力学算例可执行
M05	有界制造公差	规范已定义
M06	子结构复用与接口完整性	规范已定义
M07	偏位偏角失效边界搜索	规范已定义
M08	故障恢复与可信排名	规范已定义

每道任务均需独立输入、产物清单与评分器。后续隐藏变体不能用于调试提示词；八道任务不能支撑广泛的能力排名。

2.1 M01: 载荷、单位与平衡

审查阶梯轴向杆，确定端部约束与载荷符号，求端位移、支座反力、各段应力和应变能。调用所给轴向求解工具获取执行证据并验证平衡。将四类结果和求解产物编号写入 solution。不得声称这是三维 Abaqus 结果。

2.2 M02: 力学驱动网格分配

导入可公开实体，在给定载荷和关注量下自主选择细化区域，划分二阶四面体，在自由度预算内完成网格敏感性验证，交付输入文件及完整质量证据。

2.3 M03: 非线性预压与接触

实施规定的先预压后插入接触分析，不修改材料、摩擦与接触物理，提取全部指定法向接触通道并核验塑性、终点与能量。

2.4 M04: 自主子结构区域决策

为给定一维装配选择 CORE 与可凝聚 SUB，在整个载荷包络中保留活动非线性/接触而非仅看基线帧。调用 condensation_test 验证方案。solution 应包含 core_regions、sub_regions、retained_dofs、relative_tip_error、artifact_id，并解释依据。这是弹簧链力学算例，不是 Abaqus 子结构实测。

2.5 M05: 有界制造公差

将几何 shape、独立小板预抬和端子 X/Y 平移映射到有界正态幅值，生成含明确物理尺度的样本，核验独立控制点、刚体平移、网格质量与规定接口策略。

2.6 M06: 子结构复用与接口完整性

按来源、保留自由度、节点编号和坐标选择或拒绝候选子结构库，仅装配兼容库并完成 datacheck 和实际接口覆盖核验，不能只靠同名文件或增大 Tie 容差。

2.7 M07: 偏位偏角失效边界搜索

固定制造公差后自主安排试算，探查公端整体初始偏位/偏角下的插入失效边界，核验规定终点的接触力，不假设全局单调、不将求解失败当物理失效。

2.8 M08: 故障恢复与可信排名

恢复含数值、网格、资源和中断故障的批次，保留成功结果和物理条件，仅修复有证据的错误，对完整接触结果排名并明确排除缺通道或未达终点的 case。

3 两道已执行任务的力学依据

3.1 M01：力平衡与解析对照

阶梯杆采用毫米、牛顿、兆帕单位制。工具通过直接刚度法求解，评分器另用串联杆解析解核验。检查位移、反力符号、各段应力和应变能。

$$u_{\text{tip}} = F\sum_i \frac{L_i}{E_i A_i}, \qquad R = -F, \tag{1}$$

$$\sigma_i = \frac{F}{A_i}, \qquad \mathcal{U} = \frac{1}{2}F u_{\text{tip}}. \tag{2}$$

3.2 M04：活动非线性与静力凝聚

任务不是将所有低应力区域删除。六段串联系统中，r4 与 r6 在载荷包络内进入不同刚度分支，因此必须保留其活动非线性。线性连续段 r1 至 r3 可凝聚内部自由度 1、2，固定端 0 与接口 3 仍保留。下式通过求解线性系统实现，而不显式求逆。

$$\overline{\mathbf{K}} = \mathbf{K}_{rr} - \mathbf{K}_{ri}\mathbf{K}_{ii}^{-1}\mathbf{K}_{ir}. \tag{3}$$

正确分区的端位移在 1、5、12 N 载荷下与完整双线性系统一致。错误地把所有段冻结为线性时，高载荷端位移发生偏差。此验证仅针对一维力学算例，不代表 Abaqus 工业子结构性能。

4 真实试跑结果及边界

Kimi 使用 CCS 现有密钥与只读清单返回的 kimi-k2.6。DeepSeek 使用原配置的 deepseek-v4-flash 请求标识，通过真实 Pi SDK 执行。服务商内部别名映射并非始终可观测，不能仅凭模型自述

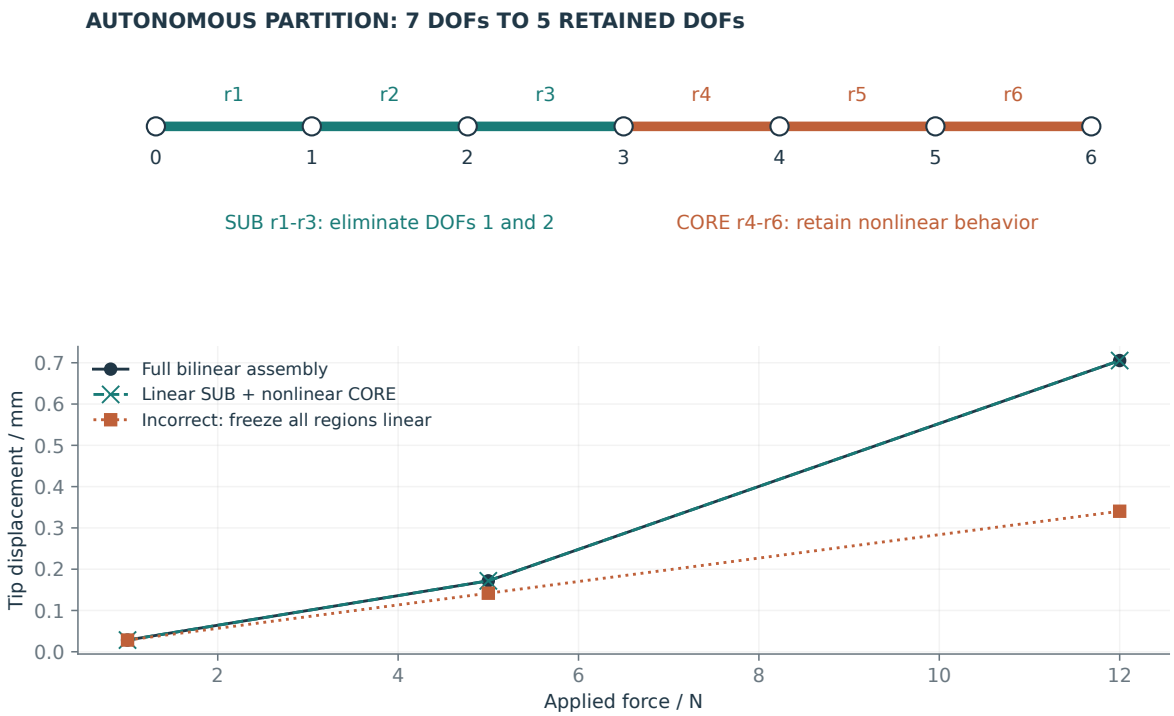


图 2: 分区与载荷包络验证。曲线来自公开算例的实际数值计算，不是连接器试验数据。

确认底层版本。

题目	配置	秒	结果
M01	Pi + DeepSeek	6.88	通过
M04	Pi + DeepSeek	16.36	通过
M01	mini + Kimi	37.25	通过
M04	mini + Kimi	122.72	输出预算耗尽

输出预算为每请求 4096 token；Kimi 的 M04 试跑在该预算下未提交解答。该结果是预算条件下的未完成，不代表无条件的力学能力判断。原 kimi-k2.5 返回 404、首次 Pi 工具注册错误，均保留且从有效次数中排除。模型和框架在两组之间同时改变，因此不得把耗时差异归因于单一因素。

5 评分、轨迹与费用

两道已执行题均使用明确数值子项，而不是语言模型主观裁判。没有求解或凝聚产物不能满分；错误分区、漏接口、伪报误差及没有任何实际自由度减少的方案分别扣分。全保留方案可能物理正确，但不获得降阶收益分。完整三维赛道的误差阈值、资源预算和指标仍需独立参考算例标定后冻结。

每次请求和返回、工具参数和结果、Pi 可导出会话、最终提交与评分均写入 JSONL 和中英文可阅读附录。原始轨迹保留，包括被排除的探测；不重构厂商未暴露的提示或思维过程。文件以 SHA256 校验。参评模型没有文件、shell、任意代码或网络工具；这不是对任意原生 agent 的操作系统隔离承诺。

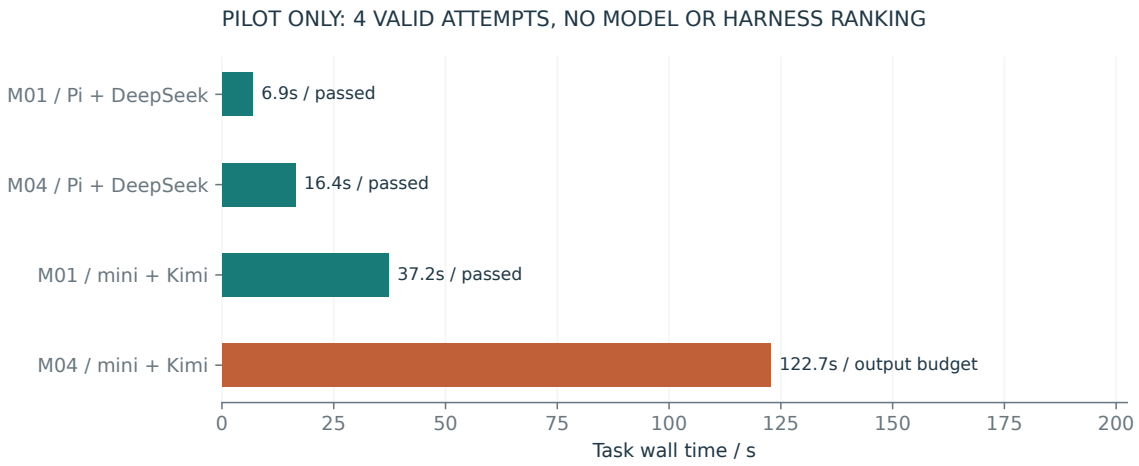


图 3: 四次有效试跑的墙钟时间与结果，不构成模型或框架排名。橙色表示预算耗尽，不是接触失效或求解器失效。

输入、缓存读写与输出 token 分别记录，推理若已含于输出不重复累加。API 账单未知；Pi SDK 的零成本字段只是元数据占位，不能解释为免费。作者的连接探测、写报告和制图不计入参评任务耗时或 token。正式 96 次重复评测尚未启动。

6 复现与下一阶段

在项目根目录运行下列命令。密钥由 CCS 只读数据库解析，无需复制到命令或配置文件。输出目录必须不存在。

```
python -m mechanics_benchmark inventory
python -m mechanics_benchmark tasks
python -m unittest discover -s mechanics_benchmark/tests -v
```

下一阶段为 M02、M03、M05 至 M08 补齐可公开三维输入、真实软件执行及独立评分，扩展 M04 至实际子结构区域决策，再冻结比较矩阵与费用上限。原 APP、工业模型、历史任务和 CCS 当前线路均未改动。

6.1 随附证据

源码包包含题目卡、中英文逐轮 query/output 附录、原始轨迹、数值产物、汇总 CSV/JSON、哈希清单及 Tavotto 脚本与导出回执。未包含 CCS 数据库、商业软件、API 密钥、私有几何或工业仿真数据。