PUBLIC ENGINEERING EVALUATION / 2026.11.04

# 力学工程 Agent 八题可执行基准

真实子结构决策、受控工具与可审计证据

AlexanderChan / v0.2.2

## 交付范围

八道题均有可执行工具与独立判分器。其中一道调用真实 Abaqus，其余七道为明确标注的简化力学或工程证据算例。本次是单次开发试跑，不是模型排行榜，也不是八道商业软件任务全部完成。

## 目录

**1 评测动机与工程范围 2**

**2 八道题的物理与判分 2**

2.1 S01 单位、串联柔度与平衡 . . . . . 2

2.2 S02 面向目标响应的网格分配 . . . . . 2

2.3 S03 独立预抬与单边接触 . . . . . 3

2.4 S04 三维子结构自主分区 . . . . . 3

2.5 S05 有界抽样及物理公差映射 . . . . . 3

2.6 S06 复用、几何兼容与绑定覆盖 . . . . . 3

2.7 S07 偏位偏角耦合首失效边界 . . . . . 3

2.8 S08 故障恢复与可信排序 . . . . . 4

**3 真实三维求解与独立校准 4**

**4 冻结试跑结果 5**

**5 复现与扩展操作 6**

**6 证据、安全与解释边界 7**

# 1 评测动机与工程范围

基准围绕连接器仿真工作流中的自主决策组织：明确载荷和量纲、选择网格精度、配置独立预抬、决定线性子结构区域、生成有界制造公差、验证库复用、搜索偏位偏角边界，以及从失败任务中恢复。重点不在于解释看起来合理，而在于能否交付可检查的产物。

CORE 指保留显式有限元描述的区域，SUB 指生成子结构的区域；case 指一组输入及其输出，不代表特定客户或型号。FEM 为 Finite Element Method（有限元法），DOF 为 Degree of Freedom（自由度），MCP 为 Model Context Protocol（模型上下文协议）；Pi 是 agent 执行框架而非模型。

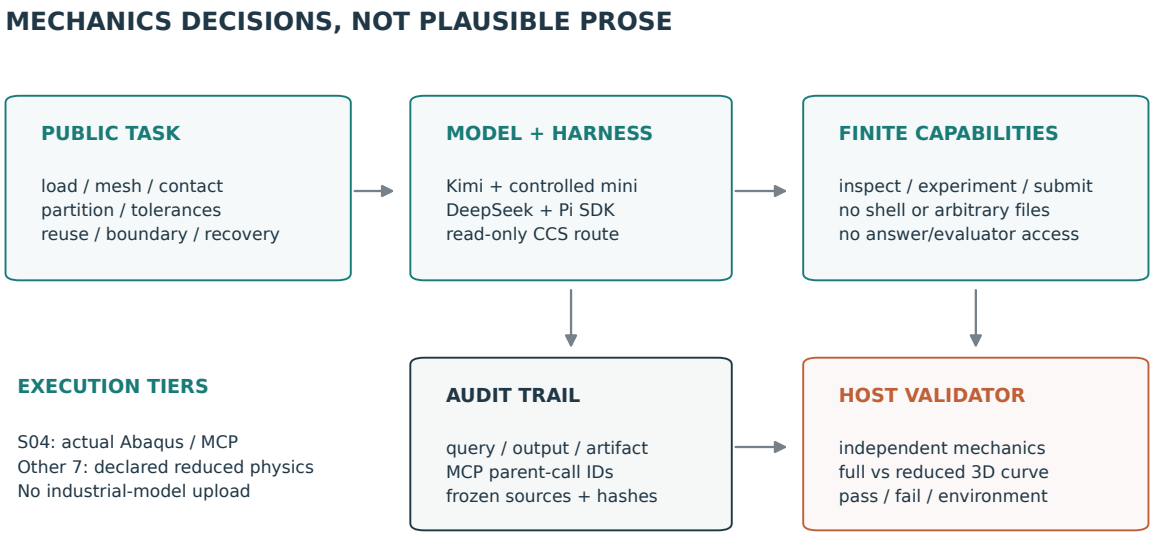



**图 1:** 模型、框架、工具、证据与判分分层。只有 S04 运行商业求解器。

# 2 八道题的物理与判分

## 2.1 S01 单位、串联柔度与平衡

轴向有限元采用分段弹性杆。独立参考通过柔度串联得到端位移，再核验根部反力与应变能。单位从 GPa 转为 MPa 后参与计算，避免仅靠结果量级判断正确性。

$$u = F \sum_i \frac{L_i}{E_i A_i}, \qquad R = -F, \qquad W = \frac{1}{2} F u$$

## 2.2 S02 面向目标响应的网格分配

面积随坐标变化，线性单元使用中点面积，目标响应为端位移。模型需要在给定离散层级中选择满足误差要求的最少单元，而不是单纯选最细网格。评分将数值柔度与连续体积分比较。

$$u_{\text{exact}} = \frac{F}{E} \int_0^1 \frac{dx}{1+x} = \frac{F}{E} \ln 2$$

### 2.3 S03 独立预抬与单边接触

六块小板分别控制相邻两对接触，预抬在名义值上独立变化。采用单边法向弹簧，分离时法向力为零；优化目标为幅值平方和最小。该题验证预抬分配及接触开启判据，不等价于三维摩擦接触。

$$N_j = k_j \max\{0, d + h_0 + 0.15a_{\lceil j/2 \rceil} - g_j\}$$

### 2.4 S04 三维子结构自主分区

这是本版本唯一真实商业求解器题。公开杆件含线弹性半段和 J2 弹塑性半段，模型在 2、4、6、8mm 候选截面间选择分区，并保留根部及接口平移自由度。子结构通过真实 Abaqus/MCP 生成，随后装配求解并读取 ODB。非线性本构区不能为了减少自由度而凝聚为线性区域。

$$K_c = K_{bb} - K_{bi}K_{ii}^{-1}K_{ib}, \qquad n_{\text{elim}} = 27(c-1)$$

### 2.5 S05 有界抽样及物理公差映射

72 维变量包括 42 个 Z 向 shape、6 个独立预抬及 12 根公端子的 X/Y 平移。四种方法均先在单位超立方体采样，再通过截断正态逆分布变换映射到 [-1,1]。这是条件分布，不是把超界值裁剪到端点。平移仅改变位置，不改变端子尺寸；子结构本身不平移。

$$a = \Phi^{-1}[\Phi(-1) + u\{\Phi(1) - \Phi(-1)\}], \quad u \in (0,1)$$

### 2.6 S06 复用、几何兼容与绑定覆盖

复用先核对拓扑、材料及保留节点坐标。只有身份兼容的库才进入装配；局部 CORE 偏移通过不调整节点位置的 Tie 覆盖判定。Tie 容差只解决几何搜索范围，不能掩盖错误的材料、网格或保留自由度。当前覆盖检查是平面解析几何，不是实际 Tie 求解。

$$t_{\min} = |n_x|\Delta x_{\max} + |n_y|\Delta y_{\max} + 10^{-6}\ \text{mm}$$

### 2.7 S07 偏位偏角耦合首失效边界

沿指定的偏位偏角耦合路径搜索首次失效，而不是在二维空间中随意寻找一个低接触力点。每次试验返回 12 对法向力，最终需要安全端与失效端的两个实测产物，且区间宽度不超过 0.002。该题是刚体杠杆加接触弹簧模型，边界数值不用于预测工业连接器。

$$g(\lambda) = \min_j N_j(\lambda) - 0.4,$$
$$N_j(\lambda) = k_j \max\{0, \delta_j - 0.1n_{x,j}\lambda - \ell_j \sin(2\lambda\pi/180)\}$$

### 2.8 S08 故障恢复与可信排序

每个 case 先验证求解完成、目标位移到达和 12 对通道完整，再取绝对法向力的最小值排序。数值中止不是接触失效。恢复操作区分重新求解、仅重提取、等待活动任务和修复负体积网格，避免重复提交尚在运行的任务。

$$N_{\min,c} = \min_{j=1,\dots,12} |N_{c,j}(U_{3,\text{final}})|$$

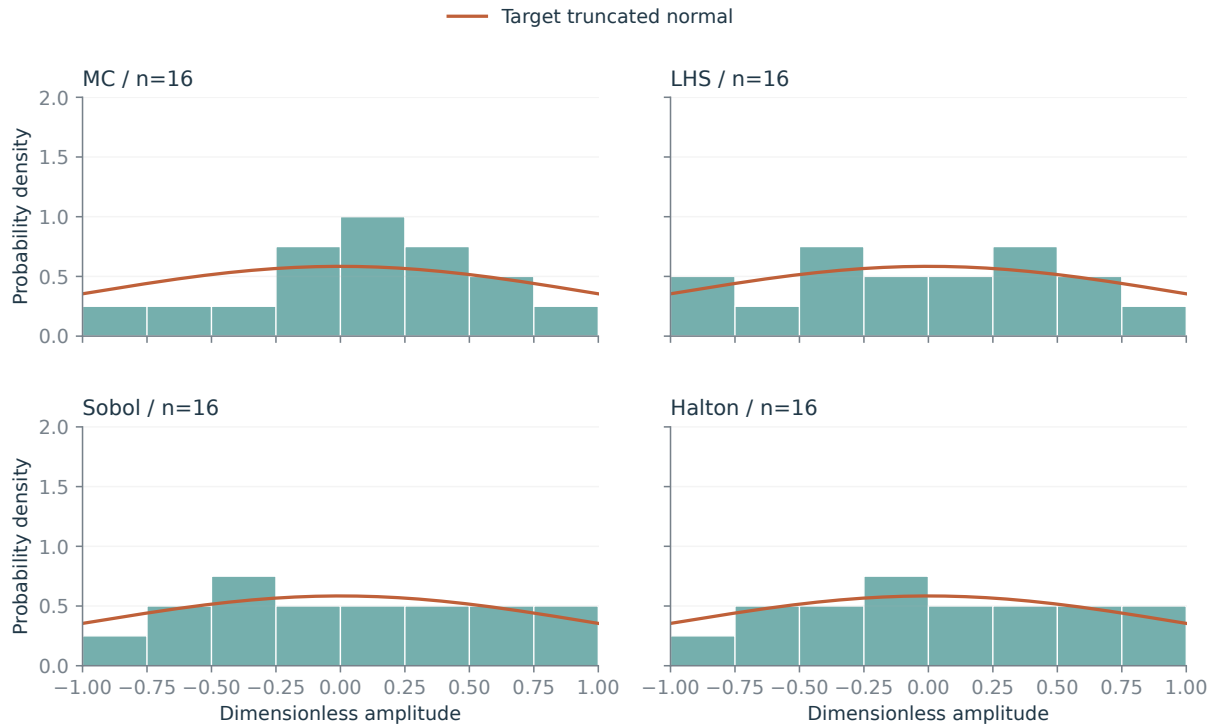



**图 2:** 四种抽样方法的单个代表变量，16 个样本；目标曲线为 [-1,1] 截断正态。仅展示抽样规则，不能据此比较统计效率。

## 3 真实三维求解与独立校准

原创建模尺寸为 12×2×2mm，117 节点、48 个 C3D8 单元。完整三维模型先独立求解；agent 不能直接读取参考结果。分区题只向模型提供材料、网格规则和候选截面，实际工具完成子结构生成、降阶装配、求解及 ODB 场提取。

校验覆盖弹性段解析解、端点位移、力平衡、塑性激活以及完整反力曲线等价性。校准反力为 7.40683N，完整与降阶的存储帧反力一致，最优安全分区消去 135 个内部平移自由度。三维塑性状态不以一维塑性近似作为精确参考；该近似早期偏差已保留于诊断记录。微型算例不用于宣称工业加速比。

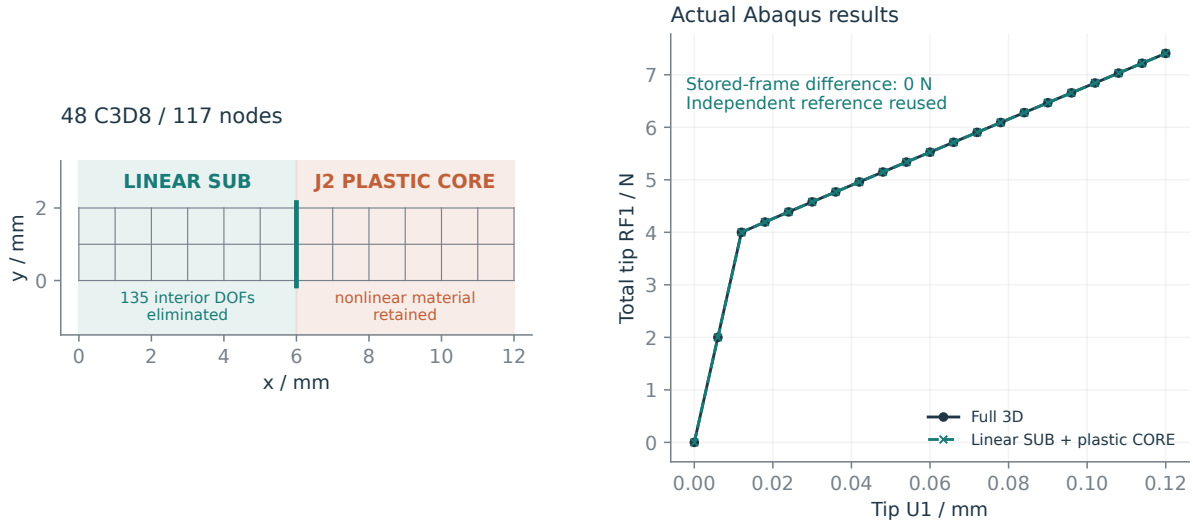



**图 3:** 真实 Abaqus 完整与降阶反力曲线；侧图为公开网格及材料分区，不是工业模型。

## 4 冻结试跑结果

源代码、题目和评分规则先冻结再调用 API。首轮八次及另外冻结的两次题面复核全部保留；S06 布尔类型、S08 排序方向以及复核中的恢复策略约定存在题面不足，共三次原始分数不用于能力评估。没有重试预算失败。合计 10 次记录，通过 4 次，服务或环境错误 1 次，协议歧义排除 3 次，有效尝试 6 次。

| Task | Configuration | Tier | s | Outcome |
|---|---|---|---|---|
| S01 | kimi-mini | Reduced | 17.8 | Environment error |
| S02 | deepseek-pi | Reduced | 14.1 | Passed |
| S03 | kimi-mini | Reduced | 277.5 | Failed / budget |
| S04 | deepseek-pi | CAE | 63.3 | Passed |
| S05 | kimi-mini | Reduced | 41.1 | Passed |
| S06 | deepseek-pi | Reduced | 9.3 | Task ambiguity (excluded) |
| S07 | kimi-mini | Reduced | 158.9 | Failed / budget |
| S08 | deepseek-pi | Reduced | 27.4 | Task ambiguity (excluded) |
| S06* | deepseek-pi | Reduced | 9.4 | Passed |
| S08* | deepseek-pi | Reduced | 10.0 | Policy ambiguity (excluded) |

Kimi 请求标识为 kimi-k2.6，使用受控 mini 框架；DeepSeek 请求标识为 deepseek-v4-flash，使用 Pi SDK0.73.1。CCS 只读解析凭据，不改变当前线路。服务端实际模型别名不总是可观测，因此保留请求标识与响应标识，不从模型自述推断身份。

每题最多 6 次模型调用，每次 6144 输出 token，24 次工具调用，三维题最多一次候选求解。Pi 推理设置为 off；不同服务端的内部推理行为不能假定一致。token 按 API 报告分项统计；SDK 零成本字段不是免费，实际账单未知。Kimi 遇到组织 RPM 限制的原始响应保留，公开版本仅隐去账号标识。

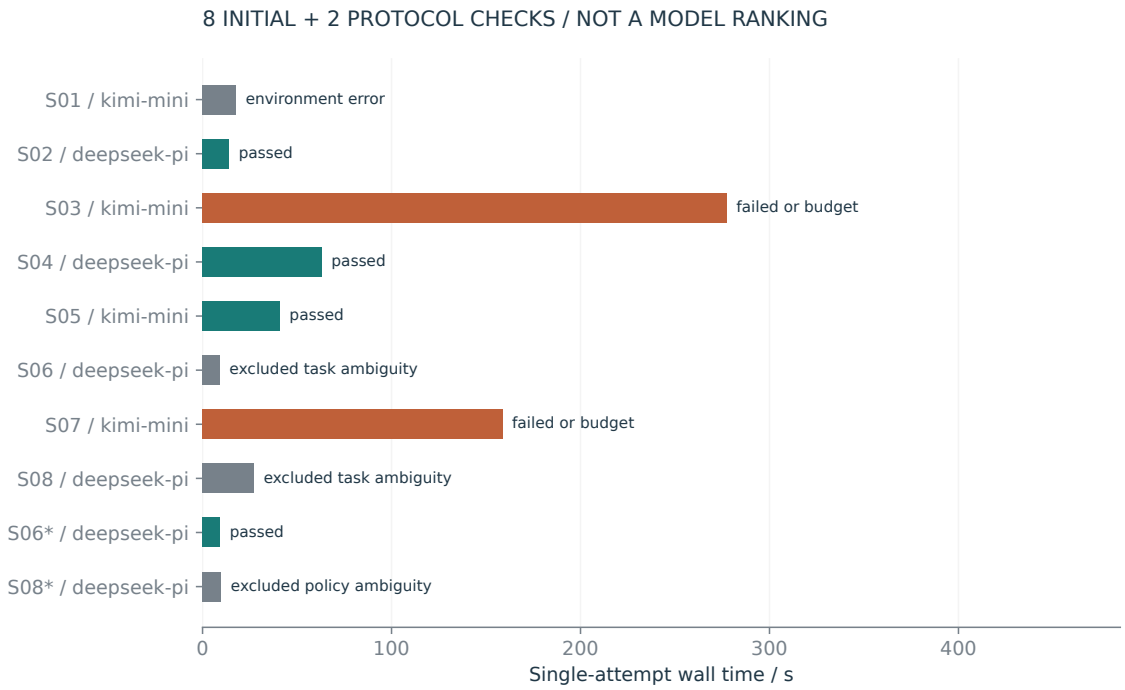



**图 4:** 按任务展示的单次耗时和状态；任务、模型、框架同时变化，不能据此排名。

表中星号标记题面复核。S06 复核通过；S08 复核正确识别并排序了低接触力 case，但建议重新求解已完成的物理失效 case，与判分器的最小恢复策略不一致。该策略此前没有完整写入题面，因此其原始零分也排除，不解释成模型力学错误。交付题库 v0.2.2 已补全约定，未继续调用 API 验证这一修订。原始判分器和新旧记录均保留。

首次冻结记录了 Python 源码哈希；后续题面修改后，通过原哈希逐文件精确匹配恢复旧源码快照，恢复过程与校验回执公开。Pi 桥接脚本及依赖文件初次未预先哈希，仅有执行后的版本证据，这一限制保留说明；新冻结命令已同时快照并哈希这些文件。

## 5 复现与扩展操作

解压源码包后，在项目根目录安装 requirements.txt 中的依赖。离线测试不需要 API 或商业软件。标准库 SQLite 只读访问本机 CCS，不要上传数据库或把密钥写入配置文件。Pi 运行时需单独安装，商业软件和 MCP 部署不随包提供。

```
python -m unittest discover -s mechanics_benchmark/tests -q
python -m mechanics_benchmark.run_suite freeze --output NEW_OUTPUT
python -m mechanics_benchmark.run_suite run --output NEW_OUTPUT
--task S04 --configuration deepseek-pi --reference REFERENCE_DIR
```

冻结命令记录环境版本与源码哈希；修改评分代码或输入后应使用新目录，不覆盖旧成绩。真实三维任务还需要 MCP 环境 Python、独立参考目录及可写求解目录；默认路径集中在 `run_suite.py` 和 `suite_tools.py`，可在部署时修改后重新冻结。每个任务目录包含 run.json、

query.json、trace.jsonl、submission.json（若提交）、artifacts 和 evaluation.json。

新增模型时添加只读路由解析与明确模型标识；新增框架时实现相同能力工具接口、逐轮事件和预算控制，先验证无 shell、任意文件与网络工具泄漏，再进行实际推理。当前验证过的只有 mini 与 Pi，不能宣称所有本机 agent 已兼容。

## 6 证据、安全与解释边界

中英文附录逐条保留可观测 query、request、output、工具参数、工具返回及原生 MCP 调用的父调用编号。原始 JSONL 是审计依据，不补写未公开的系统提示或内部思维。SHA256 清单覆盖发布文件。公开包排除私有工程几何、合同、完整工业样本、凭据、商业软件及 ODB/SIM 大文件，仅包含原创公开算例与必要求解回执。

这是具备八题执行闭环的开发基准，不是已完成的全面工业验证。真实 HyperMesh 自适应网格、三维摩擦接触、公差形变质量及所有原生 agent 客户端隔离仍属于扩展阶段。后续正式比较需使用相同任务的交叉模型/框架矩阵、多次重复、预先冻结的统计分析和费用上限。

## 参考资料

1. Abaqus 2025, Retained nodal DOFs.
2. Abaqus 2025, Substructuring theory.
3. SciPy, Quasi-Monte Carlo documentation; installed version recorded in preregistration.